

IFT 712: Devoir n°2

- caiy2401 - CAI Yunfan

1- [1.5 point] Prouvez que la régression de Ridge ayant pour objectif de minimiser la fonction d'énergie suivante (voir les notes pdf sur la régression linéaire):

$$E(\vec{w}) = \sum_{n=1}^N (t_n - \vec{w}^T \vec{\phi}(\vec{x}_n))^2 + \lambda \vec{w}^T \vec{w}$$

a pour solution l'équation suivante :

$$\vec{w} = (\Phi^T \Phi + \lambda I)^{-1} \Phi^T t.$$

On veut minimiser la fonction alors:

$$\begin{aligned} 0 &= \nabla_{\vec{w}} E(\vec{w}) \\ 0 &= - \sum_{n=1}^N [(t_n - \vec{w}^T \vec{\phi}(x_n)) \vec{\phi}(x_n) + \lambda \vec{w}] \\ 0 &= \sum_{n=1}^N [\vec{w}^T \vec{\phi}(x_n) \vec{\phi}(x_n) - t_n \vec{\phi}(x_n)] + \lambda \vec{w} \\ \sum_{n=1}^N t_n \vec{\phi}(x_n) &= \sum_{n=1}^N [\vec{w}^T \vec{\phi}(x_n) \vec{\phi}(x_n)] + \lambda \vec{w} \\ T^T \Phi &= \vec{w}^T \cdot (\lambda I + \Phi^T \Phi) \\ \vec{w}^T &= T^T \Phi \cdot (\lambda I + \Phi^T \Phi)^{-1} \\ \vec{w} &= (T^T \Phi \cdot (\lambda I + \Phi^T \Phi)^{-1})^T \\ \vec{w} &= ((\lambda I + \Phi^T \Phi)^T)^{-1} \cdot (T^T \Phi)^T \\ \vec{w} &= (\lambda I + \Phi^T \Phi)^{-1} \cdot \Phi^T T \end{aligned}$$

d'où le résultat

2- [2.5 points] Nous avons vu que l'objectif de la régression logistique est de trouver un vecteur de paramètres \vec{w} pouvant reproduire la probabilité conditionnelle suivante

$$p(C_1|\vec{\Phi}(\vec{x})) = \sigma(\vec{w}^T \vec{\Phi}(\vec{x})).$$

Prouvez que lorsque la fonction de perte est une entropie croisée (*cross-entropy*), le gradient utilisé pour effectuer la descente de gradient est déterminé par la fonction suivante :

$$\vec{\nabla} E(\vec{w}) = \sum_{n=1}^N (y_n - t_n) \vec{\Phi}(\vec{x}_n).$$

On calcule la dérivée de $y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))$:

$$\begin{aligned} \frac{\delta}{\delta \vec{w}} (y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))) &= \frac{\delta}{\delta \vec{w}} \left(\frac{1}{1 + \exp(-\vec{w}^T \vec{\Phi}(\vec{x}_n))} \right) \\ &= \frac{\exp(-\vec{w}^T \vec{\Phi}(\vec{x}_n))}{(1 + \exp(-\vec{w}^T \vec{\Phi}(\vec{x}_n)))^2} \cdot \vec{\Phi}(\vec{x}_n) \\ &= y_{\vec{w}}^2 \cdot \vec{\Phi}(\vec{x}_n) \cdot \left(\frac{1}{y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))} - 1 \right) \cdot \vec{\Phi}(\vec{x}_n) \end{aligned}$$

On a alors :

$$\begin{aligned} E_D(\vec{w}) &= - \sum_{n=1}^N t_n \ln(y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))) + (1 - t_n) \ln(1 - y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))) \\ \nabla_{\vec{w}} E_D(\vec{w}) &= - \sum_{n=1}^N t_n \cdot \frac{\delta}{\delta \vec{w}} (y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))) \cdot \frac{1}{y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))} + (1 - t_n) \cdot \frac{-1}{1 - y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))} \cdot \frac{\delta}{\delta \vec{w}} (y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))) \\ &= - \sum_{n=1}^N \frac{\delta}{\delta \vec{w}} (y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))) \cdot \left(\frac{t_n}{y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))} - \frac{(1-t_n)}{1-y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))} \right) \\ &= - \sum_{n=1}^N (y_{\vec{w}}^2(\vec{\Phi}(\vec{x}_n))) \cdot \left(\frac{1}{y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))} - 1 \right) \cdot \vec{\Phi}(\vec{x}_n) \cdot \left(\frac{t_n}{y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))} - \frac{(1-t_n)}{1-y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))} \right) \\ &= - \sum_{n=1}^N (y_{\vec{w}}^2(\vec{\Phi}(\vec{x}_n))) \cdot \left(\frac{1 - y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))}{y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))} \right) \cdot \vec{\Phi}(\vec{x}_n) \cdot \left(\frac{t_n \cdot (1 - y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))) - (1 - t_n) \cdot y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))}{y_{\vec{w}}(\vec{\Phi}(\vec{x}_n)) (1 - y_{\vec{w}}(\vec{\Phi}(\vec{x}_n)))} \right) \\ &= - \sum_{n=1}^N (y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))) \cdot (1 - y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))) \cdot \vec{\Phi}(\vec{x}_n) \cdot \left(\frac{t_n \cdot (1 - y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))) - (1 - t_n) \cdot y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))}{y_{\vec{w}}(\vec{\Phi}(\vec{x}_n)) (1 - y_{\vec{w}}(\vec{\Phi}(\vec{x}_n)))} \right) \\ &= - \sum_{n=1}^N \vec{\Phi}(\vec{x}_n) \cdot (t_n \cdot (1 - y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))) - (1 - t_n) \cdot y_{\vec{w}}(\vec{\Phi}(\vec{x}_n))) \\ &= - \sum_{n=1}^N t_n \cdot \vec{\Phi}(\vec{x}_n) - t_n \cdot y_{\vec{w}}(\vec{\Phi}(\vec{x}_n)) \cdot \vec{\Phi}(\vec{x}_n) - y_{\vec{w}}(\vec{\Phi}(\vec{x}_n)) \cdot \vec{\Phi}(\vec{x}_n) + t_n \cdot y_{\vec{w}}(\vec{\Phi}(\vec{x}_n)) \cdot \vec{\Phi}(\vec{x}_n) \\ &= - \sum_{n=1}^N t_n \cdot \vec{\Phi}(\vec{x}_n) - y_{\vec{w}}(\vec{\Phi}(\vec{x}_n)) \cdot \vec{\Phi}(\vec{x}_n) \\ &= \sum_{n=1}^N (y_{\vec{w}}(\vec{\Phi}(\vec{x}_n)) - t_n) \vec{\Phi}(\vec{x}_n) \end{aligned}$$

3- [1.0 point] Soit une variable aléatoire X pouvant prendre 3 valeurs possibles $\{1,2,3\}$ avec probabilités $P(X=1) = p_1$, $P(X=2) = p_2$ et $P(X=3) = p_3$. Démontrez que la loi de probabilité ayant l'entropie la plus élevée et satisfaisant la contrainte $p_1 = 2p_2$ a les probabilités suivantes :

$$p_1 = \frac{2}{2^{2/3} + 3}, p_2 = \frac{1}{2^{2/3} + 3}, p_3 = \frac{2^{2/3}}{2^{2/3} + 3}$$

Pour ce faire, utilisez des multiplicateurs de Lagrange afin de tenir compte de la contrainte de sommation à 1 et de la contrainte $p_1 = 2p_2$. Pour le calcul de l'entropie, prenez un logarithme en base 2.

$$p_1 = \frac{2}{2^{2/3} + 3}, p_2 = \frac{1}{2^{2/3} + 3}, p_3 = \frac{2^{2/3}}{2^{2/3} + 3}$$

On a :

$$E(I[X]) = \sum_{i=1}^3 p_i \log_2(p_i)$$

$$\text{avec } p_1 + p_2 + p_3 = 1 \text{ et } p_1 = 2p_2$$

$$1. \text{ on obtient: } g_1(p_1, p_2, p_3) = p_1 + p_2 + p_3 - 1 = 0$$

$$g_2(p_1, p_2, p_3) = p_1 - 2p_2 = 0$$

alors :

$$E(I[X]) = -p_1 \log_2 p_1 - p_2 \log_2 p_2 - p_3 \log_2 p_3$$

et :

$$\mathcal{L} = -p_1 \log_2 p_1 - p_2 \log_2 p_2 - p_3 \log_2 p_3 + \lambda_1(p_1 - 2p_2) + \lambda_2(p_1 + p_2 + p_3 - 1)$$

$$\frac{\delta \mathcal{L}}{\delta p_1} = -\frac{1}{\ln 2} \cdot p_1 \cdot \frac{1}{p_1} - \log_2 p_1 + \lambda_1 + \lambda_2 = 0$$

$$\Rightarrow \log_2 p_1 = -\frac{1}{\ln 2} + \lambda_1 + \lambda_2$$

$$\Rightarrow p_1 = 2^{(\lambda_1 + \lambda_2 - \frac{1}{\ln 2})}$$

$$\frac{\delta \mathcal{L}}{\delta p_2} = -\frac{1}{\ln 2} \cdot p_2 \cdot \frac{1}{p_2} - \log_2 p_2 - 2\lambda_1 + \lambda_2 = 0$$

$$\Rightarrow \log_2 p_2 = -\frac{1}{\ln 2} - 2\lambda_1 + \lambda_2$$

$$\Rightarrow p_2 = 2^{(-2\lambda_1 + \lambda_2 - \frac{1}{\ln 2})}$$

$$\frac{\delta \mathcal{L}}{\delta p_3} = -\frac{1}{\ln 2} \cdot p_3 \cdot \frac{1}{p_3} - \log_2 p_3 + \lambda_2 = 0$$

$$\Rightarrow \log_2 p_3 = -\frac{1}{\ln 2} + \lambda_2$$

$$\Rightarrow p_3 = 2^{(\lambda_2 - \frac{1}{\ln 2})}$$

$$\text{on en d duit que } p_1 = 2^{\lambda_1} p_3 \quad p_2 = 2^{-2\lambda_1} p_3$$

donc en rempla ant dans g_2 :

$$g_2(p_1, p_2, p_3) = p_1 - 2p_2 = 0$$

$$\Leftrightarrow 2^{\lambda_1} p_3 - 2 \cdot 2^{-2\lambda_1} p_3 = 0$$

$$\Leftrightarrow p_3 (2^{\lambda_1} - 2^{-2\lambda_1 + 1}) = 0$$

$$\Leftrightarrow 2^{\lambda_1} = 2^{-2\lambda_1 + 1}$$

$$\Leftrightarrow \lambda_1 = -2\lambda_1 + 1$$

$$\Leftrightarrow \lambda_1 = 1/3$$

de plus on a $g_1(p_1, p_2, p_3) = p_1 + p_2 + p_3 - 1 = 3p_2 + p_3 - 1 = 0$

$$\Leftrightarrow p_3 + 3 \cdot 2^{-2/3} p_3 = 1$$

$$\Leftrightarrow p_3 = \frac{1}{1+3 \cdot 2^{-\frac{2}{3}}} = \frac{2^{2/3}}{2^{2/3}+3}$$

$$\text{et} \quad \Rightarrow p_2 = 2^{-\frac{2}{3}} p_3 = \frac{1}{2^{2/3}+3}$$

$$\text{et} \quad \Rightarrow p_1 = 2p_2 = \frac{2}{2^{2/3}+3}$$